

逻辑回归

其实我们并不需要确切地算出概率密度，算出决策边界足矣。

名称	模型	损失函数	参数更新方程
感知机	$g(x) = sign(w^T x + w_0)$	$\ell(w, b) = -r^{(\ell)}(w^T x^{(\ell)} + b)$	$\boldsymbol{w} \leftarrow \boldsymbol{w} + \eta r^{(\ell)} x^{(\ell)}$ if $r^{(\ell)} g_i(x^{(\ell)}) \leq 0$
Sigmoid	$y = \text{sigmoid}(w^T x + w_0)$ $= \frac{1}{1 + \exp[-(w^T x + w_0)]}$	$\ell(w, w_0 \mid x, r) = -r \log y - (1 - r) \log (1 - y)$ $L(w, w_0 \mid D) = -\sum_{l=1}^N r^{(l)} \log y^{(l)} + (1 - r^{(l)}) \log (1 - y^{(l)})$	$\boldsymbol{w} \leftarrow \boldsymbol{w} + \sum_{l=1}^N (r^{(l)} - y^{(l)}) x_j^{(l)}$
SoftMax	$y_i = \text{softmax}(w_i^T x + w_{i0})$ $= \frac{\exp[w_i^T x + w_{i0}]}{\sum_{j=1}^K \exp[w_j^T x + w_{j0}]}$ ($i = 1, \dots, K$)	$L(\boldsymbol{w} \mid \boldsymbol{x}, \boldsymbol{r}) = -\sum_{i=1}^K r_i \log y_i$ $L(\boldsymbol{w} \mid D) = -\sum_{l=1}^N \left[\sum_{i=1}^K r_i^{(l)} \log y_i^{(l)} \right]$	$\boldsymbol{w} \leftarrow \boldsymbol{w} + \sum_{l=1}^N (r^{(l)} - y^{(l)}) x_j^{(l)}$

分析

- 感知机：
 - 对训练数据集要求较高，只能处理线性可分的数据集，并且解不唯一，存在多个解。
 - 0-1这样的离散值不能精确表示一个实例有多接近于某个类 C_i